

QUE HACE COMPETITIVO A UN MODELO PEQUENO

Guia practica para LLMs de menos de 100 millones de parametros

Tesis principal

En el rango 10M-100M, el numero de parametros es solo una parte de la historia. La calidad y mezcla de datos, el tokenizer, el presupuesto de tokens, el objetivo de entrenamiento y el protocolo de evaluacion pueden cambiar el resultado mas que duplicar el tamano del modelo.

Decisiones que multiplican valor	Efecto esperado
Datos curados y curriculum	Mas conocimiento util por parametro; menos capacidad desperdiciada.
Tokenizer adaptado al dominio	Menos fragmentacion; secuencias mas cortas y patrones mas faciles de aprender.
Destilacion o ajuste por tarea	Transfiere comportamiento de modelos grandes a una red compacta.
Evaluacion honesta	Separa progreso real de contaminacion, prompts favorables o azar.

Alcance: modelos autoregresivos base de la tabla proporcionada, mas lecciones aplicables a modelos pequenos en general.

1. Como leer los resultados

Las cinco pruebas miden capacidades distintas. ARC-Easy y ARC-Challenge son preguntas de ciencia escolar; HellaSwag mide continuacion de sentido comun; PIQA, razonamiento fisico cotidiano; y ArithMark, aritmetica. En ARC y HellaSwag hay cuatro opciones: 25% es aproximadamente azar. En PIQA hay dos: 50% es aproximadamente azar.

Por eso un 31% en HellaSwag indica una mejora, pero todavia pequena; y un 23%-25% en ARC-Challenge se debe interpretar con mucha cautela. El rendimiento util depende de la tarea final, no de un promedio ciego.

Senal en la tabla	Lectura correcta	Implicacion
Supra-1.5-50M lidera ARC-Easy (48.40)	Fuerte para conocimiento escolar basico a 51.8M.	Candidato generalista eficiente.
Veyra2 lidera PIQA (62.13) y HellaSwag (31.28)	Mejor sentido comun / fisica cotidiana entre los 50M.	Buen punto de partida para asistentes de texto cortos.
Gros-Michel-90M v2 lidera ArithMark (35.90)	Mejor perfil numerico de la lista.	Elegir si las respuestas contienen calculo.
Pythia-70M queda bajo Pythia-31M	Mas parametros sin receta mejor no garantizan mejora.	Los datos y el entrenamiento dominan en esta escala.

Promedio simple orientativo: Supra ~39.6, Gros-Michel v2 ~39.2, BananaMind ~38.4, Veyra2 ~38.2 y Nexus ~37.1. No es una metrica oficial: mezcla tareas, escalas y posibles conjuntos de entrenamiento diferentes.

2. Que aporta cada componente

Componente	Que cambia dentro del modelo	Por que pesa mas en 10M-100M
Arquitectura	Profundidad, ancho, atencion, normalizacion, MLP y longitud de contexto.	Define donde cabe la capacidad, pero no crea conocimiento por si sola. Debe ser facil de optimizar.
Tokenizer	Convierte texto a tokens. Decide vocabulario, fragmentacion y manejo de numeros/codigo.	Cada token ahorrado equivale a mas contexto y mas ejemplos vistos con el mismo compute.
Datos de preentrenamiento	Aportan lenguaje, hechos, estilo y patrones de razonamiento.	Un modelo pequeno no puede memorizar ruido: necesita alta densidad de senal.
Mezcla y curriculum	Ordena y pondera documentos: texto general, educativo, codigo, QA, sintetico.	Permite especializar sin perder fluidez; evita que una fuente masiva domine todo.
Objetivo de entrenamiento	Prediccion del siguiente token, mascara, denoising o tareas auxiliares.	Induce las habilidades que el modelo practicara.
Distilacion / SFT	Imita distribuciones o respuestas de un profesor grande.	Es la via mas directa para adquirir conducta util sin aumentar parametros.
Inferencia	Prompt, formato de opciones, temperatura, longitud de salida.	Puede desbloquear o esconder capacidad ya aprendida, pero no sustituye entrenamiento.

Regla operativa: antes de aumentar de 50M a 90M, revisar cobertura de datos, ratio tokens/parametro, tokenizer y errores de validacion. Es habitual obtener mas ganancia con una segunda pasada de datos curados que con una red mayor entrenada de forma identica.

3. Datos y tokenizer: donde nacen las diferencias

Datos curados. Un corpus educativo, de preguntas-respuestas, ciencia y explicaciones fortalece ARC; historias y situaciones humanas ayudan HellaSwag; ejemplos de acciones fisicas ayudan PIQA. El riesgo es que entrenar sobre datos demasiado cercanos a un benchmark mide recuperacion o contaminacion, no generalizacion.

Mezcla. La proporcion importa. Mucho texto web puede mejorar fluidez y empeorar precision; demasiados datos sinteticos pueden reforzar formatos repetitivos. Una mezcla saludable combina texto de alta calidad, material pedagogico, dominio objetivo y una fraccion sintetica validada.

Tokenizer. Un tokenizer de 32k tokens puede ser mas eficiente que uno generico si reduce fragmentacion en el dominio. Para matematicas, mantener digitos y operadores en unidades coherentes facilita aprender estructura posicional. Nexus-Erebus declara precisamente un tokenizer consciente de digitos, una explicacion plausible para su perfil aritmetico, aunque no sustituye una evaluacion externa.

Decisión	Aporta	Riesgo / control
Filtrar duplicados, basura y texto roto	Menos gradientes inutilés; mejora calidad por token.	No filtrar material raro pero valioso; auditar muestras.
Sobremuestrear conocimiento objetivo	Mueve el modelo hacia la tarea del producto.	Sobreajuste temático; conservar un núcleo generalista.
Datos sintéticos con verificador	Escala ejemplos de cálculo, formatos y explicaciones.	Errores del generador; usar reglas, ejecución o respuestas conocidas.
Tokenizer de dominio	Menos tokens por ejemplo y patrones más consistentes.	Compatibilidad menor con modelos y corpus externos.

4. Que parece aportar a cada familia de tu tabla

No todas las tarjetas publican el mismo detalle de entrenamiento; por tanto esta es una interpretacion de los patrones observados, no una atribucion causal demostrada. La forma correcta de confirmarla es una ablation controlada.

Modelo / grupo	Patron observado	Hipotesis de valor	Uso recomendado
Supra-1.5-50M Base	Mejor ARC-Easy y mejor promedio simple.	Receta de datos/entrenamiento generalista especialmente eficiente.	Baseline principal para 50M.
Veyra2-Apricot-50M	Mejor HellaSwag y PIQA.	Datos orientados a sentido comun y buena cobertura cotidiana.	Fluidez, clasificacion y QA cotidiana.
Gros-Michel-90M v2	Mejor ArithMark; v2 mejora a la version previa.	El cambio de receta importa mas que el salto de parametros; posible mejor mezcla numerica.	Candidata si se permite 95M.
Nexus-Erebus-50M	Competitivo en ARC-Easy y aritmetica declarada.	Tokenizer de digitos y curriculum sintetico de enteros.	Experimentos matematicos; validar contaminacion.
Pythia 14M-70M	Resultados desiguales al escalar.	Referencia de entrenamiento, no techo de capacidad actual.	Control reproducible de ablations.
SLM-10M / GPT-S 5M	PIQA muy por encima de azar con capacidades limitadas.	Incluso micro-modelos absorben regularidades simples.	Demos on-device y experimentos educativos.

La comparacion Supra vs. modelos de 90M es la leccion mas accionable: si dos modelos comparten la misma evaluacion, ganar ARC-Easy con 51.8M frente a opciones de 75M-95M sugiere que el presupuesto debe ir primero a datos y a iteraciones de receta.

5. Como demostrar que una mejora es real

Un leaderboard es un filtro inicial, no la decision final. Re-evaluar los checkpoints candidatos con el mismo codigo, commit de harness, prompt, numero de ejemplos (0-shot / few-shot), normalizacion de probabilidad y conjuntos completos. Registrar semilla y version de cada artefacto.

Prueba	Que evita	Decision que habilita
Conjunto interno en espanol y fuera de distribucion	Elegir por benchmarks ingleses que no representan el producto.	Seleccion de modelo para el caso de uso real.
Ablation: mismo modelo, un factor a la vez	Atribuir una ganancia al parametro equivocado.	Saber si gano el tokenizer, datos o entrenamiento.
Contaminacion: deduplicar contra test y buscar n-gramas	Memorizacion de preguntas de benchmark.	Credibilidad del resultado.
Curvas de perdida y de benchmark por tokens	Parar demasiado pronto o sobreentrenar una mezcla.	Asignacion eficiente de compute.
Latencia, RAM y tokens/s con el hardware objetivo	Optimizar solo accuracy.	Viabilidad de despliegue.

Protocolo minimo para el hackathon: (1) elegir Supra, Veyra2 y Gros-Michel v2; (2) correr los cinco benchmarks con un harness fijado; (3) crear 200-500 items propios en espanol, separados de entrenamiento; (4) comparar exactitud, latencia y memoria; (5) inspeccionar manualmente 30 fallos por modelo.

Recomendacion final: para un limite estricto de 50M, empezar con Supra-1.5-50M y Veyra2-Apricot-50M. Si calculo es central o se admite 95M, incluir Gros-Michel-90M v2. Usar Pythia-31M como control historico, no como candidato ganador.

6. Fuentes y notas de reproducibilidad

La tabla de partida fue facilitada por el usuario. Los resultados deben interpretarse solo si los modelos se evaluaron con el mismo protocolo. Las fuentes siguientes documentan conceptos y ejemplos mencionados en el informe.

[1] Microsoft, MiniLM README. Resultados de destilación y comparación de parámetros.
<https://github.com/microsoft/unilm/blob/master/minilm/README.md>

[2] Wang et al. (2020), MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression. <https://arxiv.org/abs/2002.10957>

[3] Chung et al. (2022), Scaling Instruction-Finetuned Language Models / FLAN Collection. <https://arxiv.org/abs/2210.11416>

[4] AxiomicLabs, Open SLM Leaderboard y configuración de entradas. https://huggingface.co/spaces/AxiomicLabs/Open_SLM_Leaderboard

[5] MaliosDark, Nexus-Erebus-50M model card: arquitectura, tokenizer y protocolo declarado.
<https://huggingface.co/MaliosDark/Nexus-Erebus-50M>

[6] AxiomicLabs, ArithMark 3.0 dataset card. <https://huggingface.co/datasets/AxiomicLabs/Arithmark-3.0>

Nota de cautela

Una puntuación publicada por la propia tarjeta de un modelo es evidencia útil, pero no independiente. Prioriza benchmarks reproducibles, conjuntos de prueba no vistos y comparaciones con versiones fijadas. Los resultados de ArithMark-2 y ArithMark-3 no son intercambiables; no deben compararse como si fuesen la misma métrica.